Kettős Könyvelés

Feladatleírás · Téli Országos Válogató

2026. október 17.



1. Kettős Könyvelés

Egy hazai vasúttársaságnál minden vonat útját két, egymástól független rendszer rögzíti. A forgalmi napló a menetrendből és a diszpécserek jelentéseiből dolgozik: tudja, hány megállója van a vonatnak, mennyi a menetrend szerinti menetideje, és mekkora késéssel indult, illetve érkezett. A GPS-szolgáltató ezzel szemben csak azt látja, amit a szerelvényre szerelt eszköz nagyjából percenként jelent: mennyi ideig mozgott a vonat, mekkora utat tett meg, hányszor állt meg, és milyen sebességgel haladt.

A két rendszer rekordjait egy közös azonosító kötötte össze. Egy elhibázott adatbázis-migráció során azonban a szeptember 1. utáni rekordok azonosítói elvesztek, a két tábla sorai pedig összekeveredtek. A korábbi adatok épen maradtak, ott minden útnál tudjuk, melyik naplóbejegyzés melyik GPS-rekordhoz tartozik.

A migráció után egyetlen információt sikerült megmenteni: minden rekordról tudjuk, melyik nap melyik órájában indult a vonat. A rekordok ennek megfelelően *blokkokba* vannak rendezve. Egy blokk egy adott nap egy adott órájában induló összes utat tartalmazza, a két táblában pontosan ugyanazokat az utakat, csak más sorrendben és más azonosítókkal.

Téged kértek fel, hogy állítsd helyre a kapcsolatot: a szeptemberi GPS-rekordok mindegyikéhez keresd meg a forgalmi napló azon bejegyzését, amely ugyanahhoz az úthoz tartozik.

2. Amit megkapsz

A `train.csv` fájl 59 848 korábbi utat tartalmaz (augusztus 14. és szeptember 1. között), 435 blokkba rendezve. Minden sor egy utat ír le, a forgalmi napló és a GPS-szolgáltató adataival együtt, tehát itt a párok ismertek.

A `test_a.csv` a forgalmi napló, a `test_b.csv` a GPS-szolgáltató szeptemberi rekordjait tartalmazza (szeptember 2. és 8. között). Mindkét fájlban 22 868 sor van, 156 blokkba rendezve. A naplóbejegyzéseket az `a_id`, a GPS-rekordokat a `b_id` azonosítja; a két azonosító között nincs összefüggés. Mindhárom fájlban szerepel a `block` (a blokk azonosítója) és az `hour` (az indulás órája) oszlop.

A forgalmi napló oszlopai:

Oszlop	Jelentés
`sched_duration`	menetrend szerinti menetidő (perc)
`n_stops`	megállások száma a kiinduló- és a végállomással együtt
`distance`	a kiinduló- és a végállomás légvonalbeli távolsága (km)
`mean_dwell`	átlagos menetrend szerinti tartózkodási idő (perc)
`train_type`	vonatnem (0: személyvonat, 1: InterRégió, sebes- és gyorsvonat, 2: InterCity)
`departure_delay`	rögzített indulási késés (perc)
`arrival_delay`	rögzített érkezési késés (perc)
`long_dwells`	legalább 2 perces menetrend szerinti megállások száma
`min_leg`, `median_leg`, `max_leg`	két szomszédos megálló közötti menetidő minimuma, mediánja, maximuma (perc)

A késéseket a diszpécserek rögzítik, ezek az értékek nem mindig pontosak.

A GPS-szolgáltató oszlopai:

Oszlop	Jelentés
`travel_time`	az első és az utolsó mozgás közben küldött jelzés között eltelt idő (perc)
`path_length`	a jelzések alapján megtett út (km)
`standstills`	hányszor állt meg a szerelvény
`stopped_share`	az álló helyzetben küldött jelzések aránya
`max_speed`, `mean_speed`	legnagyobb és átlagos mozgás közbeni sebesség (m/s)
`speed_0`, …, `speed_30_plus`	a jelzések aránya az egyes sebességsávokban (m/s)
`short_stops`, `long_stops`	a 2 percnél rövidebb, illetve legalább 2 perces megállások száma
`turning`	az irányváltozások összege kilométerenként (fok/km)

3. Amit beadsz

Egyetlen CSV fájlt `b_id,a_id` fejléccel, amelyben pontosan 22 868 sor található. A `test_b.csv` minden `b_id` azonosítója pontosan egyszer szerepeljen, mellette pedig annak a naplóbejegyzésnek az `a_id` azonosítója, amelyet a GPS-rekord párjának gondolsz. Modellt nem kell beadni; a kiértékelő a CSV-ből számolja a pontszámot.

4. A feladat pontozása

Jelölje $\mathcal{T}$ a teszthalmaz N elemű GPS-rekord halmazát, $\hat{a}_t$ a t-edik rekordhoz beadott naplóbejegyzést, és a_t^* a valódi párját. A megoldást egyetlen mérőszám alapján értékeljük:

- **Pontosság**: a helyesen párosított GPS-rekordok aránya,

$$\text{Acc} = \frac{1}{N} \sum_{t \in \mathcal{T}} \mathbf{1}\left[\hat{a}_t = a_t^*\right].$$

  Értéke $[0, 1]$ közé esik, ahol 1 a tökéletes párosításnak felel meg.

Maximális pontszám: 80 pont.

Pontozási görbe. A pontszám nem közvetlenül a pontosságból számolódik, hanem egy szakaszonként lineáris görbéből, amelyet a feladat nehézségéhez kalibráltunk.

Pontosság	$\leq 0{,}03$	$0{,}12$	$0{,}22$	$0{,}30$	$0{,}46$	$0{,}56$	$0{,}72$	$0{,}82$	$\geq 0{,}88$
Pontszám	0	8	16	24	32	40	52	64	80

A horgonypontok között lineáris interpoláció történik.

Kiértékelés. A beadott párosítást a teljes teszthalmazon értékeljük ki. Az eredmény a versenyfutam alatt is látható a ranglistán, és ez dönti el a végleges helyezést.

5. Technikai tudnivalók

A feladat megoldásához a mellékelt `.ipynb` notebook, `train.csv`, `test_a.csv` és `test_b.csv` fájlok állnak rendelkezésre. A notebook betölti az adatokat, a tanítóhalmazból leválaszt egy validációs részt, és előállít egy érvényes beadást. A megoldás feladata a 22 868 párt tartalmazó CSV-fájl előállítása.

Az engedélyezett csomagok offline dokumentációja és a virtuális Python-környezet (a JupyterLab indítószkriptjével) a http://nipg12.inf.elte.hu:2026/ címen érhető el.

A pontozást a **DOCK** platform automatikusan végzi szerveroldalon, modellt nem kell beadnod. **Legfeljebb 15 feltöltési kísérleted van**, és **a legjobb beadásod pontszáma számít** a végleges eredménybe.

6. Hasznos források

- Offline dokumentáció és versenykörnyezet: http://nipg12.inf.elte.hu:2026/
- NumPy dokumentáció
- pandas dokumentáció
- scikit-learn dokumentáció
- SciPy: `linear_sum_assignment`