MAGYAR MI DIÁKOLIMPIA

Elméleti rész

Téli Országos Válogató

2026. október 17.

Név: _____ **Versenyzői Azonosító:** _____

A feladatsor megoldására pontosan **3 óra** áll rendelkezésedre. A feladatsor **22 feladatból áll**, maximálisan **160 pontot ér**.

Ez a feladatsor a **Magyar Mesterséges Intelligencia Diákolimpia** téli válogatójának elméleti része. Papíralapon, segédeszközök használata nélkül kell megoldani.

A feladatok a következő témakörökből származnak: **keresés** (AI Search), **felügyelet nélküli tanulás** (Unsupervised Learning), **felügyelt tanulás** (Supervised Learning), **ajánlórendszerek** (Recommender Systems), **megerősítéses tanulás** (Reinforcement Learning, RL), **modellek kiértékelése** (Model Evaluation), valamint **kernelmódszerek** (Kernel Methods).

A feladatsor két részből áll. A **feleletválasztós kérdéseknél** a választ ezen a feladatlapon jelöld be. A **kifejtős feladatokat** a kiosztott külön lapokon oldd meg, és minden lapra írd fel a nevedet és a feladat sorszámát. A kifejtős feladatoknál a megoldás menetét is írd le, ne csak a végeredményt.

Pontozás a feleletválasztós kérdéseknél. A feleletválasztós kérdéseknek két típusa van.
Egyválaszos kérdések („Válaszd ki az egyetlen helyes választ”): pontosan egy helyes válasz van.

- **3 pont**: pontosan a helyes választ jelölöd be, és csak azt.
- **0 pont**: minden más esetben. Negatív pont nincs.

Több válaszlehetőséges kérdések („Válaszd ki pontosan azokat az állításokat, amelyek igazak”): tetszőleges számú állítás lehet igaz.

- **5 pont**: minden igaz állítást kiválasztasz, és csak azokat (tökéletes válasz).
- **2 pont**: kizárólag igaz állításokat választasz ki, de nem mindegyiket (azaz nem jelölsz be hamis állítást, viszont legalább egy igazat kihagysz).
- **1 pont**: pontosan egy hamis állítást jelölsz be, viszont legalább egy igaz állítást is megjelölsz. A kihagyott igaz állítások száma nem számít.
- **0 pont**: minden más esetben, vagyis ha üresen hagyod a kérdést, ha egyetlen igaz állítást sem jelölsz be, vagy ha két vagy több hamis állítást is bejelölsz. Negatív pont nincs.

Kivétel: ha a helyes válasz az, hogy „A többi állítás közül egyik sem igaz”, akkor csak akkor jár pont (5 pont), ha kizárólag ezt az opciót jelölöd be; minden más esetben 0 pont.

Sok sikert kívánunk!

Feleletválasztós kérdések

Egyválaszos kérdések

Ezeknél a kérdéseknél **pontosan egy** helyes válasz van: 3 pont jár, ha pontosan azt jelölöd be, minden más esetben 0 pont.

1. Van 1000 db 40 dimenziós vektorod, és levetíted őket 2 dimenzióra PCA-val. Hány vektorod marad? Válaszd ki az egyetlen helyes választ:
   - ◯ 2
   - ◯ 20

- ◯ 25
- ◯ 40
- ◯ 80
- ◯ 500
- √ **1000**
- ◯ 2000
- ◯ A megadott adatokból nem határozható meg.

2. Van 100 dokumentum, minden dokumentum átlagosan 60 tokent tartalmaz, és egy dokumentumban átlagosan 25 féle (egyedi) token található. Hány dimenziósak **pontosan** az ezen az adathalmazon tanított TF-IDF vektorok? Válaszd ki az egyetlen helyes választ:
   - ◯ 25
   - ◯ 60
   - ◯ 100
   - ◯ 2500
   - ◯ 6000
   - ◯ 1560
   - ◯ 156000
   - √ **A megadott adatokból nem határozható meg.**
3. Legyen A egy **szimmetrikus, pozitív definit** mátrix, amelynek ismerjük az SVD-felbontását: $A = U\Sigma V^T$. (Ilyen mátrix esetén a szinguláris felbontás egybeesik a sajátérték-felbontással, azaz $V = U$, és U ortogonális: $U^TU = I$.) Minimum hány **mátrixszorzás** elég ahhoz, hogy kiszámoljuk A^{256}-ot? (Egy diagonális mátrix elemenkénti hatványozása nem számít mátrixszorzásnak.) Válaszd ki az egyetlen helyes választ:
   - ◯ 0
   - ◯ 1
   - √ **2**
   - ◯ 8
   - ◯ 16
   - ◯ 255
   - ◯ 256
   - ◯ A megadott adatokból nem határozható meg.

Több válaszlehetőséges kérdések

Ezeknél a kérdéseknél tetszőleges számú állítás lehet igaz, a pontozás a fenti, több válaszlehetőséges kérdésekre vonatkozó szabályok szerint történik.

4. A nem informált keresésekkel kapcsolatban válaszd ki pontosan azokat az állításokat, amelyek **igazak**:
   - √ **Véges állapottérben, az ismétlődő állapotok kiszűrésével a DFS garantáltan talál megoldást, ha létezik megoldás.**
   - ◯ A szélességi keresés garantáltan talál megoldást, ha három mélységben van a legközelebbi megoldás.
   - ◯ A szélességi keresést preferáljuk a mélységivel szemben, mivel kevesebb csúcsot néz meg és jobb a memóriaigénye.

- √ **A szélességi és a mélységi keresés algoritmikailag (tehát az idő és tárhely komplexitást figyelmen kívül hagyva) kizárólag a kiterjesztés sorrendjében tér el.**
- ◯ A szélességi és az egységköltségű (Uniform Cost Search) keresés közül csak a szélességi talál garantáltan optimális megoldást különböző élköltség esetén, feltéve, hogy létezik véges távolságra megoldás (véges az elágazási faktor).
- √ **A szélességi keresés tekinthető az egységköltségű (Uniform Cost Search) keresés speciális változatának.**
- √ **A mélységi keresés tekinthető az egységköltségű (Uniform Cost Search) keresés speciális változatának.**
- ◯ A többi állítás közül egyik sem igaz.

5. Egy robot az alábbi 7×7-es rácson mozog (négy irányba léphet, # = fal). S-ből indul, és A* kereséssel megy a G cél felé. Egy cella heurisztikafüggvényének értéke a Manhattan-távolságok összege S-be és G-be, a cél mező esetén a heurisztika 0. Meglátogatott mezőnek azt nevezzük, amelyet kivettünk a nyílt listáról és kiterjesztettünk. A cél mezőt már nem terjesztjük ki, hanem rögtön megállunk, így ezt nem tekintjük meglátogatottnak.

	o0	o1	o2	o3	o4	o5	o6
s0	.	.	.	.	.	.	.
s1	.	S	.	#	.	.	.
s2	.	.	.	#	.	.	.
s3	#	#	#	#	.	.	.
s4	.	.	.	.	.	.	.
s5	.	.	#	#	#	G	.
s6	.	.	.	.	.	.	.

Válaszd ki pontosan azokat az állításokat, amelyek igazak:

- √ **Minden legkisebb heurisztikaértékű mező az S és G által kifeszített téglalapon belül van (a téglalap oldalait is beleértve).**
- √ **A meglátogatott mezők száma legalább 10.**
- √ **A meglátogatott mezők száma legalább 11.**
- √ **A meglátogatott mezők száma legalább 12.**
- ◯ A meglátogatott mezők száma **legfeljebb** 20.
- √ **A meglátogatott mezők száma legfeljebb 22.**
- ◯ Van olyan holtverseny-döntés, amelynél az `s4o0` mezőt meglátogatjuk.
- ◯ Van olyan holtverseny-döntés, amelynél az `s5o1` mezőt meglátogatjuk.
- ◯ Ez a keresés tetszőleges rácson garantáltan a legrövidebb utat találja meg ezzel a heurisztikafüggvénnyel.
- ◯ A többi állítás közül egyik sem igaz.

6. Az alábbi kérdésben „K-means" alatt az algoritmus *egyetlen* lefuttatását értjük (nem több véletlen inicializálás közül a legjobb kiválasztását).

   Tegyük fel, hogy az adathalmaz pontjai előre rögzített módon k^* csoportra vannak osztva: ezek a *valódi klaszterek*, k^* pedig a klaszterek *tényleges száma*. Jelölje D a klaszterátmérőt (az azonos valódi klaszterbe tartozó pontok közötti maximális távolság), d_{out} pedig a különböző valódi klaszterekbe tartozó pontok közötti minimális távolságot. Egy klaszterező algoritmus akkor *találja meg a valódi klasztereket*, ha az általa adott felosztás pontosan ez a k^* csoport (a klaszterek sorszámozásától eltekintve).

   Silhouette érték: egy tetszőleges felosztásban az i pontra, amelynek klaszterében rajta kívül legalább még egy pont van, legyen $a(i)$ az i átlagos távolsága a saját klaszterének többi pontjától, $b(i)$ pedig a legkisebb átlagos távolsága egy másik klaszter pontjaitól. Ekkor

$$s(i) = \frac{b(i) - a(i)}{\max\big(a(i),\, b(i)\big)},$$

egyelemű klaszter pontjára pedig $s(i) = 0$. A felosztás *silhouette score*-ja az $s(i)$ értékek átlaga.

Válaszd ki pontosan azokat az állításokat, amelyek igazak:

- ○ Ha $d_{out} > D$, akkor meg tudjuk választani a K-means és a hierarchikus klaszterezés paramétereit (a K-means esetén az inicializálási stratégiát, a hierarchikus esetén pedig az összekapcsolási módszert (linkage) is beleértve) úgy, hogy mindkettő biztosan megtalálja a valódi klasztereket.
- √ **Ha minden távolságot ugyanazzal a $c > 0$ számmal megszorzunk, a silhouette score nem változik.**
- ○ Ha minden (különböző pontok közötti) távolsághoz ugyanazt a $c > 0$ számot hozzáadjuk, a silhouette score nem változik.
- √ **Két klaszter esetén, ha egy pontot átteszünk a másik klaszterbe (és a régi klaszterében rajta kívül volt még legalább egy pont), akkor ennek a pontnak a silhouette értéke pontosan az ellentettjére változik.**
- ○ Két klaszter esetén, ha egy pontot átteszünk a másik klaszterbe (és a régi klaszterében rajta kívül volt még legalább egy pont), akkor a felosztás teljes silhouette score-ja pontosan az ellentettjére változik.
- ○ Diszkrét térben elhelyezkedő pontfelhők esetén a hagyományos (folytonos átlagszámítást alkalmazó) K-means és az adatpontokra korlátozott középpontokat használó változat azonos inicializálás esetén garantáltan ugyanahhoz a végső klaszter-kiosztáshoz konvergál.
- ○ A többi állítás közül egyik sem igaz.

7. Adott a 2D síkon 5 darab, független **csonkított** Gauss-eloszlás, amelyeknek a szórásmátrixa azonos és **izotróp**. A csonkítás azt jelenti, hogy mindegyik eloszlásnál ugyanazon valószínűségisűrűség-küszöbérték alatti pontokat elvetjük.

Izotróp eloszlás: az eloszlás minden irányban ugyanúgy szóródik. Ez azt jelenti, hogy minden koordináta mentén ugyanakkora a szórás (σ), és a koordináták korrelálatlanok, azaz a szórásmátrix $\Sigma = \sigma^2 I = \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix}$.

Az eloszlás sugara (R): a legnagyobb távolság, amely a várható érték és egy még **lehetséges** (a csonkítás után is előforduló) pont között felléphet. Nevezzük az **eloszlás területének** azt a síkidomot, ahol előfordulhatnak az adott csonkított eloszlás által generált pontok.

Mind az 5 eloszlásból **legalább 2-2 pontot** generálunk (a pontok akár egybe is eshetnek), úgy, hogy ezek a csonkítás után is megmaradjanak. Ismert, hogy az 5 eloszlásból 3 az A kategóriához, 2 pedig a B kategóriához tartozik.

Az adathalmazon agglomeratív hierarchikus klaszterezést futtatunk, a megállási feltétel: pontosan két klaszter marad. Két klaszter (X és Y) távolságát az összekapcsolási módszer (linkage) határozza meg:

- **Single-linkage:** $D(X, Y) = \min_{x \in X,\, y \in Y} d(x, y)$, a két klaszter legközelebbi pontpárjának távolsága;
- **Complete-linkage:** $D(X, Y) = \max_{x \in X,\, y \in Y} d(x, y)$, a két klaszter legtávolabbi pontpárjának távolsága.

A klaszterezéshez a feladatban **Single-linkage**-et használunk, ha mást nem mond az állítás. A szétválasztás *helyes*, ha a kapott 2 klaszter pontosan az A, illetve a B kategóriájú pontokból áll.

Válaszd ki pontosan azokat az állításokat, amelyek **igazak**:

- √ **Mind az 5 eloszlás egyforma sugarú körlapon belül generál pontokat.**
- √ **Egyetlen eloszlás területén belül két pont távolsága legfeljebb az eloszlás sugarának kétszerese.**
- ○ Az A kategóriához tartozó 3 területnek feltétlenül metszenie kell egymást ahhoz, hogy a Single-linkage biztosan egy klaszterbe vonja őket.

- ◯ A helyes szétválasztáshoz elengedhetetlen, hogy bármely két A-beli pont közelebb legyen egymáshoz, mint a legközelebbi B-beli ponthoz.
- √ **Létezik olyan geometriai elrendezés, ahol a Single-linkage garantáltan helyes eredményt ad, míg a Complete-linkage biztosan elrontja azt.**
- ◯ Ha eloszlásonként több pontot generálunk (pl. 2 helyett 1000-et), akkor a területek között kisebb távolság is elegendő ahhoz, hogy a szétválasztás a legrosszabb esetben is garantáltan helyes legyen.
- √ **Ha egy A-hoz és egy B-hez tartozó terület tömegközéppontjának távolsága kisebb, mint $2R$, létezik olyan legrosszabb esetű pontgenerálás, amely garantáltan elrontja a klaszterezést.**
- √ **Ha az azonos kategóriához tartozó területek tömegközéppontjainak maximális távolsága D_{max}, a különböző kategóriákhoz tartozóké minimálisan D_{min}, akkor $D_{max} + 4R < D_{min}$ esetén a szétválasztás garantáltan helyes.**
- ◯ Két azonos eloszlásból származó generált pont euklideszi távolsága elérheti a $4R$ értéket is.
- ◯ A többi állítás közül egyik sem igaz.

8. Az alábbi modellekben x_1, x_2, x_3 a bemeneti jellemzők (ismert adatok), y a célváltozó, a $\beta_0, \beta_1, \beta_2$ pedig a tanítás során tanult paraméterek; minden más szám rögzített konstans. Az alábbi modellek közül melyek tekinthetők **lineáris regressziónak**? Válaszd ki pontosan azokat, amelyek azok:
   - √ $y = \beta_1 \ln(x_1) + \beta_2 x_2 + \beta_0$
   - √ $y = \beta_1 \cos(x_3) + \beta_2 x_1 x_2 + \beta_0$
   - √ $y = \ln\left(x_1^{\beta_1} \cdot x_2\right) + \beta_0$
   - ◯ $y = \beta_1 x_1^{\beta_2} + \beta_0$
   - √ $y = \beta_1 x_1^2 + \beta_0$
   - ◯ $y = \dfrac{1}{\beta_1 x_1 + \beta_0}$
   - ◯ A többi állítás közül egyik sem igaz.
9. A TF-IDF-ről. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
   - ◯ A TF-IDF egy olyan módszer, amivel tokenekhez készíthetünk beágyazásokat. A hátránya, hogy az ugyanolyan szóalakkal, de különböző jelentéssel rendelkező tokenekhez (többjelentésű szavak, pl. daru, csíp...) ugyanaz a vektor tartozik.
   - ◯ TF-IDF vektorokon is működik a szemantikai algebra, azaz király $-$ férfi $+$ nő $\approx$ királynő típusú összefüggések teljesülnek.
   - √ **Egy token IDF-súlya annál nagyobb, minél kevesebb dokumentumban fordul elő.**
   - ◯ A TF-IDF reprezentáció figyelembe veszi a szavak sorrendjét a dokumentumban.
   - √ **A TF-IDF mátrix jellemzően ritka (sparse): egy dokumentum vektorában a koordináták túlnyomó része 0.**
   - √ **Ha egy token a korpusz minden dokumentumában előfordul, az IDF-súlya (simítás nélkül) 0 lesz.**
   - ◯ A többi állítás közül egyik sem igaz.
10. Az állapotokról, akciókról és jutalmakról. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
    - ◯ A jutalom mindig független az állapottól.
    - ◯ A jutalom értéke nemnegatív.
    - ◯ Egy adott állapotban mindig véges számú akció áll rendelkezésre.
    - √ **Egy állapot többször is előfordulhat egy trajektória során.**
    - √ **Az állapotátmenetek lehetnek determinisztikusak.**

- ◯ Minden trajektória elér egy terminális állapotot.
- ◯ A többi állítás közül egyik sem igaz.

11. A Q-learning algoritmusról. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
    - ◯ On-policy algoritmus.
    - √ **Off-policy algoritmus.**
    - √ **Célja, hogy megtalálja az optimális $Q^*(s,a)$ függvényt.**
    - ◯ Célja, hogy megtalálja az optimális $V^*(s)$ függvényt.
    - ◯ Működési elve, hogy a $V(s)$ értékeket iteratív módon pontosítja, majd ezekből kiszámítja a $Q^*(s,a)$ értékeket.
    - ◯ Működési elve, hogy az összes $Q(s,a)$ értékre felírt Bellman-egyenlet egyenletrendszerét (ez a Q mátrix) analitikus módon megoldja.
    - ◯ A többi állítás közül egyik sem igaz.
12. A Temporal Difference (TD) Learning (időkülönbséges tanulás) algoritmusokról. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
    - ◯ Csak véges számosságú állapottereken működnek.
    - ◯ Mindig on-policy algoritmusok.
    - ◯ Az állapotérték- vagy állapot-akció érték-függvény frissítése mindig egy trajektória végén történik.
    - √ **A bootstrapping módszerrel becsült értékek alapján frissítenek becsült értékeket.**
    - ◯ A többi állítás közül egyik sem igaz.

Kifejtős feladatok

A kifejtős feladatokat a kiosztott külön lapokon oldd meg, a feladat sorszámának feltüntetésével.

13. **(6 pont)** Adott a síkon az alábbi 6 pont:

$$P_1 = (0,0), \quad P_2 = (2,0), \quad P_3 = (0,2), \quad P_4 = (4,4), \quad P_5 = (6,4), \quad P_6 = (4,6).$$

$K = 2$ klasztert keresünk, a kezdeti klaszterközéppontok: $c_1 = (0,0)$ és $c_2 = (2,0)$. A távolság az euklideszi távolság.

(a) **(2 pont)** Írj pszeudokódot a K-means algoritmushoz!

(b) **(2 pont)** Végezd el a K-means **egy** iterációját: add meg, melyik pont melyik klaszterbe kerül, és mik lesznek az új klaszterközéppontok!

(c) **(2 pont)** Változik-e a pontok klaszterbe sorolása a következő iterációban? Ha igen, melyik pont kerül át?

Megoldás:

(a) Egy lehetséges pszeudokód ($x_1, \ldots, x_n$ a pontok, z_i az i-edik pont klasztere):

K-means$(x_1, \ldots, x_n,\ K)$:
  $c_1, \ldots, c_K \leftarrow$ a kezdeti középpontok
  ismételd
    minden i-re: $z_i \leftarrow \arg\min_j \|x_i - c_j\|^2$ (hozzárendelés)
    minden j-re: $c_j \leftarrow$ az $\{x_i | z_i = j\}$ pontok átlaga (frissítés)
  amíg a z hozzárendelés változott
  visszaad $z,\ c_1, \ldots, c_K$

Bármilyen ezzel egyenértékű leírás elfogadható, amelyben szerepel az inicializálás, a hozzárendelési és a frissítési lépés, valamint a leállási feltétel.

(b) Négyzetes távolságokkal: $P_1, P_3 \to 1$, $P_2, P_4, P_5, P_6 \to 2$. Az új középpontok $c_1 = (0,1)$ és $c_2 = \left(4, \frac{7}{2}\right)$.

(c) Igen, P_2 átkerül az 1. klaszterbe: $d^2(P_2, c_1) = 5$, míg $d^2(P_2, c_2) = 16{,}25$. Ezután $c_1 = \left(\frac{2}{3}, \frac{2}{3}\right)$, $c_2 = \left(\frac{14}{3}, \frac{14}{3}\right)$, és a hozzárendelés már nem változik: $\{P_1, P_2, P_3\}$, $\{P_4, P_5, P_6\}$.

Pontozás (összesen 6 pont):

- (a) Inicializálás, hozzárendelés, frissítés (update), megállási feltétel: 0,5–0,5 pont.
- (b) Helyes eljárást ad arra, hogy eldöntse, melyik középpont van közelebb (ha csak felrajzolja, az is elfogadható): 1 pont; helyes eredmény: 1 pont.
- (c) Helyes eljárást ad az új középpontok kiszámolására és a távolságok meghatározására: 1 pont; helyes középpontokat kap: 1 pont.

14. **(9 pont)** Írd fel az egyenes illesztésének az egyenletrendszerét a legkisebb négyzetek módszerével a következő pontokra, majd oldd is meg!

$$(1,\ 2), \quad (2,\ 3), \quad (3,\ 5), \quad (4,\ 6)$$

Megoldás: A modell $\hat{y} = mx + b$, a minimalizálandó hiba $L(m,b) = \sum_i (y_i - mx_i - b)^2$. A parciális deriváltakat nullázva a normálegyenletek:

$$m\sum x_i^2 + b\sum x_i = \sum x_i y_i, \qquad m\sum x_i + n\,b = \sum y_i.$$

Az összegek ($n = 4$):

x_i	y_i	x_i^2	$x_i y_i$
1	2	1	2
2	3	4	6
3	5	9	15
4	6	16	24
$\sum = 10$	$\sum = 16$	$\sum = 30$	$\sum = 47$

A behelyettesített egyenletrendszer:

$$\begin{cases} 30m + 10b = 47 \\ 10m + \ \ 4b = 16 \end{cases}$$

A második egyenlet $2{,}5$-szeresét ($25m + 10b = 40$) az elsőből kivonva $5m = 7$, azaz $m = 1{,}4$. Visszahelyettesítve a második egyenletbe: $14 + 4b = 16$, tehát $b = 0{,}5$.

Az illesztett egyenes: $\hat{y} = 1{,}4x + 0{,}5$.

Pontozás (összesen 9 pont):

- Felírja az egyenletrendszert (normálegyenleteket): 4 pont.
- Helyes módszerrel elkezdi kiszámolni az együtthatókat: 4 pont.
- Helyes végeredmény ($m = 1{,}4$, $b = 0{,}5$): 1 pont.

15. **(6 pont)** Adott egy adathalmaz, amelyen egy bináris döntési fát (pl. CART algoritmus) tanítunk. A tanítás során a vágások pontosan addig folytatódnak, amíg minden levélcsomópont (leaf) teljesen „tiszta” nem lesz, azaz minden levélben kizárólag egyetlen kategóriába (osztályba) tartozó elemek maradnak. A fa mélységét úgy definiáljuk, mint a gyökércsomóponttól a legmélyebb levélig vezető út éleinek (döntési lépéseinek) a száma (tehát egyetlen vágás után a fa mélysége 1). Mekkora az elméletileg lehetséges legkisebb (minimális) és legnagyobb (maximális) famélység, ha az adathalmaz pontosan 10 különböző osztályba tartozó elemet tartalmaz? Általánosítva, mekkora a minimális és maximális famélység egy N különböző osztályba tartozó elemből álló adathalmaz esetén? (Elég a 10 elemes esetre a végeredményt, az általános esetre pedig a képletet megadni, a helyességüket nem kell bizonyítani.)

Megoldás: Minimum: $\lceil \log_2 10 \rceil = 4$, általánosan $\lceil \log_2 N \rceil$. A d mélységű fának legfeljebb 2^d levele van, és minden elemnek külön levél kell, tehát $2^d \geq N$. Ezt a kiegyensúlyozott, felező vágásokkal épített fa el is éri.

Maximum: 9, általánosan $N - 1$. A láncszerű fában minden vágás egyetlen elemet választ le, így $N - 1$ vágás után marad az utolsó elem. (Az indoklás nem része az elvárt válasznak, csak a javítók tájékoztatására szolgál.)

Pontozás (összesen 6 pont):

- 10 elemre a minimális és a maximális mélység: 1–1 pont.
- Általános képlet a minimális és a maximális mélységre: 2–2 pont.

16. **(9 pont)** Egy lineáris SVM tartóvektorai a következők:

- a $+1$ osztályban: $\mathbf{x}_1 = (3,\, 1)$ és $\mathbf{x}_2 = (1,\, 3)$,
- a -1 osztályban: $\mathbf{x}_3 = (0,\, 0)$.

Add meg a döntési határ (decision boundary) egyenletét, a $\mathbf{w}$ súlyvektort, a b biast és a margó szélességét!

Megoldás: Legyen $\mathbf{w} = (w_1, w_2)$. A tartóvektorok a margón vannak, tehát mindegyikre $y_i(\mathbf{w}\cdot\mathbf{x}_i + b) = 1$. Ez három egyenlet a három ismeretlenre (w_1, w_2, b):

$$\begin{cases} 3w_1 + \;\; w_2 + b \;\; = 1 & (\mathbf{x}_1,\; y_1 = +1) \\ \;\; w_1 + 3w_2 + b \;\; = 1 & (\mathbf{x}_2,\; y_2 = +1) \\ -(0\cdot w_1 + 0\cdot w_2 + b) = 1 & (\mathbf{x}_3,\; y_3 = -1) \end{cases}$$

A harmadikból $b = -1$. Ezt beírva $3w_1 + w_2 = 2$ és $w_1 + 3w_2 = 2$; a kettő különbsége $2w_1 - 2w_2 = 0$, azaz $w_1 = w_2$, így $4w_1 = 2$, tehát $w_1 = w_2 = \frac{1}{2}$:

$$\mathbf{w} = \left(\tfrac{1}{2}, \tfrac{1}{2}\right), \qquad b = -1.$$

A döntési határ $\mathbf{w}\cdot\mathbf{x} + b = 0$, azaz $\frac{1}{2}x + \frac{1}{2}y - 1 = 0$, vagyis $x + y = 2$. A margó szélessége

$$\frac{2}{\|\mathbf{w}\|} = \frac{2}{\sqrt{\frac{1}{4} + \frac{1}{4}}} = \frac{2}{1/\sqrt{2}} = 2\sqrt{2}.$$

(Ellenőrzés: a két margóegyenes $x + y = 4$, amelyen $\mathbf{x}_1$ és $\mathbf{x}_2$ rajta van, és $x + y = 0$, amelyen $\mathbf{x}_3$; ezek távolsága $4/\sqrt{2} = 2\sqrt{2}$.)

Pontozás (összesen 9 pont):

- Felírja az egyenletrendszert (a tartóvektorokra $y_i(\mathbf{w}\cdot\mathbf{x}_i + b) = 1$): 4 pont.
- Kiszámolja a súlyvektort és a biast: 1 pont.
- Felírja a margó képletét: 3 pont.
- Kiszámolja a margót: 1 pont.

17. **(7 pont)** Egy Naiv Bayes számítást kell kiértékelned egy orvosi adathalmazon, amely egy betegség meglétét jósolja meg ($Y \in \{\text{Igen}, \text{Nem}\}$), két jellemző alapján:

- X_1: Vérnyomás (folytonos, tegyük fel, hogy osztályonként normális, azaz Gauss-eloszlású),
- X_2: Vércsoport (kategorikus: A, B, AB, O).

Az $Y = \text{Igen}$ osztályhoz $N_{\text{Igen}} = 10$ beteg tartozik, míg az $Y = \text{Nem}$ osztályhoz $N_{\text{Nem}} = 20$ páciens. A tanító adathalmaz statisztikái az Igen osztályhoz:

- X_1 statisztikák: $\mu = 140$, $\sigma^2 = 25$,
- X_2 darabszámok: $A : 6,\; B : 4,\; AB : 0,\; O : 0$.

Egy új beteghez tartozó tesztrekord: $X_1 = 145$, $X_2 = O$.

(a) **(1 pont)** Számítsd ki a $P(X_1 = 145, X_2 = O \mid Y = \text{Igen})$ likelihood értéket simítás nélkül!

(b) **(6 pont)** Számítsd ki ugyanezt a likelihood értéket Add-1 (Laplace) simítás használatával a kategorikus jellemzőre!

(A Gauss-sűrűségfüggvény: $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$. A (b) részfeladatnál elég a **képlet behelyettesített alakja**, a szám kiszámolása nem elvárás.)

Megoldás: A naiv feltevés miatt $P(X_1, X_2 \mid Y) = P(X_1 \mid Y) \cdot P(X_2 \mid Y)$.

(a) $P(X_2 = O \mid \text{Igen}) = \frac{0}{10} = 0$, tehát a likelihood pontosan 0 (zero-frequency probléma).

(b) $P(X_2 = O \mid \text{Igen}) = \frac{0+1}{10+4} = \frac{1}{14}$, és $f(145) = \frac{1}{5\sqrt{2\pi}} e^{-1/2}$, így

$$P(X_1 = 145, X_2 = O \mid \text{Igen}) = \frac{e^{-1/2}}{5\sqrt{2\pi}} \cdot \frac{1}{14} \approx 0{,}0035.$$

Pontozás (összesen 7 pont):

- (a) Helyes eredmény (0): 1 pont.
- (b) Felírja a simított képletet a kategorikus jellemzőre: 3 pont.
- (b) Felírja a képletet a folytonos jellemzőre (Gauss-sűrűség): 2 pont.
- (b) Helyes eredmény (a behelyettesített alak is elfogadható): 1 pont.

18. **(5 pont)** Egy adatbázis megsérült, és az alábbi két vektor csak hiányosan olvasható ki belőle (az olvashatatlanná vált értékeket □ jelöli):

$$A = \left(\tfrac{2}{3},\ \square,\ \tfrac{1}{3}\right), \qquad B = \left(\tfrac{1}{3},\ \tfrac{2}{3},\ \square\right)$$

A metaadatokból annyit tudunk, hogy a sérülés előtt mindkét vektor egységvektor volt, és minden koordinátájuk nemnegatív. Mekkora a két vektor koszinusz hasonlósága?

Megoldás: Egységvektorra a hiányzó koordináta négyzete $1 - \frac{4}{9} - \frac{1}{9} = \frac{4}{9}$, a nemnegativitás miatt $A_2 = B_3 = \frac{2}{3}$. Egységvektoroknál a koszinusz hasonlóság a skaláris szorzat:

$$\cos(A, B) = \tfrac{2}{9} + \tfrac{4}{9} + \tfrac{2}{9} = \tfrac{8}{9}.$$

Pontozás (összesen 5 pont):

- Felírja az egységvektor feltételét: 2 pont.
- Helyesen kijönnek a hiányzó koordináták: 1 pont.
- Felírja a koszinusz hasonlóság képletét: 1 pont.
- Helyes eredmény ($\frac{8}{9}$): 1 pont.

19. **(5 pont)** Van egy jellemződ, X (pl. egy ház mérete) és egy célváltozód, Y (pl. a ház ára). A köztük lévő Pearson-korreláció $r = 0{,}8$. Mekkora lesz az új korrelációs együttható, $r(X', Y')$, ha $X' = -3X + 5$ és $Y' = 2Y - 10$? Indokold a megoldásod!

Megoldás: $r(X', Y') = -0{,}8$. Indoklás: $r(X, Y) = \dfrac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$. Az eltolás sem a kovarianciát, sem a szórást nem változtatja meg, a skálázásra pedig $\mathrm{Cov}(aX + b, cY + d) = ac\,\mathrm{Cov}(X, Y)$ és

$\sigma_{aX+b} = |a|\,\sigma_X$, $\sigma_{cY+d} = |c|\,\sigma_Y$. Így

$$r(aX+b,\, cY+d) = \frac{ac}{|a|\,|c|}\, r(X,Y) = \mathrm{sgn}(a)\,\mathrm{sgn}(c)\, r(X,Y),$$

itt $a = -3 < 0$ és $c = 2 > 0$, tehát $r(X', Y') = -0{,}8$.

Pontozás (összesen 5 pont):

- Indoklás: 4 pont.
- Helyes eredmény ($-0{,}8$): 1 pont.

20. **(6 pont)** Milyen értékek között tud változni a koszinusz hasonlóság értéke neurális háló által előállított szóbeágyazások esetén? Illetve TF-IDF vektorok esetén? A lehető legszűkebb intervallumot add meg! Indokold a megoldásod!

Megoldás: Neurális beágyazásoknál $[-1, 1]$, mert a koordináták tetszőleges előjelűek lehetnek, így bármilyen bezárt szög előfordulhat (ellentétes irányú vektoroknál -1, azonos irányúaknál 1). TF-IDF vektoroknál $[0, 1]$, mert a koordináták nemnegatívak, így a skaláris szorzat sem lehet negatív: a vektorok a nemnegatív ortánsban vannak, a bezárt szög legfeljebb $90°$. Mindkét végpont előfordul: 0, ha a két dokumentumnak nincs közös szava, 1, ha a két vektor azonos irányú (pl. azonos dokumentumok).

Pontozás (összesen 6 pont):

- Indoklás a neurális beágyazásokra és a TF-IDF vektorokra: 2, illetve 1 pont.
- Helyes intervallum a neurális beágyazásokra és a TF-IDF vektorokra: 2, illetve 1 pont.

21. **(37 pont) MEeT RICk.** Rick szeret fordítani, csak nem ért hozzá, így kedvenc fordító modelljén dolgozik, melyet szeretne minél jobbra betanítani.

Rick észrevette, hogy a modell nagyon gyakran teljesít egész jól, viszont a hibátlan fordítások aránya csekély. Jobban megvizsgálva, a kimenet jelentős része szinte mindig értelmes és helyes, viszont a modell el-elront egy-egy tokent szinte minden példában.

(a) **(13 pont)** Rick feltevését igazolandó, szeretne egy olyan mérőszámot adni, mely minden egyes kimenethez megadja, hogy mennyire felel meg az elvárt kimenetnek. Ennek a mérőszámnak különösen fontos, hogy jól megkülönböztesse a teljesen hibátlan kimeneteket a hibásaktól. Ugyanakkor, ha már előfordult egy hiba, akkor a további (nem nagyobb) hibákat ne büntesse ugyanolyan mértékben, csupán kisebb súllyal. Emellett Rick azt is szeretné, hogy a módszer folytonos legyen: ha egy kicsit eltérő kimeneti eloszlásokat ad vissza a modell (az egyes pozíciókra), akkor ne változzon sokat a mérőszám értéke (akkor se, ha éppen átbillen a teljesen helyes és a hibás kimenet között ez az érték).

A bemenet egy p sorozat, amelynek minden eleme az adott pozíción lévő tokeneloszlás, amelyet a modell visszaadott. Itt feltehetjük, hogy $p_{k,i} \in [0, 1]$, ahol a k-adik pozíció eloszlása p_k, és $\sum_j p_{k,j} = 1$ (vagyis ténylegesen egy eloszlásról beszélünk). A jelölés kedvéért feltehetjük, hogy a k-adik pozíció elvárt kimenete a $g(k)$-edik elem, vagyis helyes eredmény esetén a $p_{k,g(k)}$ elem értéke a legnagyobb.

Tehát az alábbi pontoknak kell megfelelnie a mérőszámnak:

- Jelentősen visszaesik a teljesítmény az első elrontott token után, viszont a következő elrontott tokent már nem bünteti ugyanilyen mértékben, akár figyelmen kívül is hagyhatja.
- A sikerességnek 0 és 1 közötti értéknek kell lennie (0 a legrosszabb, és 1 a legjobb).
- Kicsi változás a modell kimenetében (p) ne változtasson túl sokat a mérőszámon.

Adj meg egy, a fenti leírásnak megfelelő mérőszámot, és mutasd meg, miért teljesíti a fent megfogalmazott elvárásokat!

(b) **(24 pont)** Rick szeretné úgy kiegészíteni a fenti elvárásait, hogy minden hibás token számítson bele negatívan a kimenetbe, ne csak a legrosszabb, viszont minél kisebb a hiba a legrosszabbhoz képest, annál kevésbé legyen szignifikáns az okozott romlás. Adj meg egy ennek is megfelelő mérőszámot! A válaszodat részletesen indokold!

Megoldás:

(a) Kiindulhatunk a helyes tokenek átlagos log-valószínűségéből: $\frac{1}{N}\sum_{k=1}^{N}\log p_{k,g(k)} = \frac{1}{N}\log\prod_{k=1}^{N} p_{k,g(k)}$. Egyetlen kis érték ezt lehúzza, de több hasonló hiba lineárisan rontja ($\log a + \log a = 2\log a$), vagyis a hibák számával arányosan büntet. Az arányosság eltűnik, ha átlag helyett minimumot veszünk, majd az exponenciálissal visszaképezünk $[0,1]$-be. Az e^x szigorú monotonitása miatt ez egyenértékű ezzel:

$$M(p) = \min_k p_{k,g(k)} \in [0,1].$$

A minimum folytonos, értéke $[0,1]$-be esik, és csak akkor 1, ha minden pozíción 1 a helyes token valószínűsége. A legrosszabb token egymaga meghatározza az értéket, így az első hiba nagyot ront, a további, nem nagyobb hibákat pedig figyelmen kívül hagyja, amit az elvárások kifejezetten megengednek.

(b) Rendezzük a helyes tokenek valószínűségeit növekvő sorrendbe: $p_{(1)} \le p_{(2)} \le \cdots \le p_{(N)}$, ahol $p_{(1)}$ a legrosszabb token. Legyen

$$M(p) = \prod_{i=1}^{N} p_{(i)}^{1/i}.$$

Minden tényező $[0,1]$-be esik, így $M(p) \in [0,1]$, hibátlan kimenetre pedig minden tényező 1, tehát $M = 1$. A rendezett értékek folytonosan függnek p-től, így M is folytonos. A legrosszabb token teljes súllyal számít ($M \le p_{(1)}$), ezért az első hiba ugyanúgy jelentősen ront, mint az (a) részben. Minden további hibás token is csökkenti az értéket, de egyre kisebb kitevővel, és minél közelebb van $p_{(i)}$ az 1-hez, annál kisebb a hatása. Más, a feltételeknek megfelelő mérőszám is elfogadható.

22. **(16 pont) Kernel magozás.** Hosszú idő után Bergengócia királyának sikerült felvennie a kapcsolatot Csodaország uralkodójával. A művelet nem volt egyszerű, és sajnos a továbbiakban sem lesz az, tekintve, hogy a két ország különböző méretű dimenziókban létezik. A megoldást egy varázskernel (K) biztosítja: a szokásos módon átküldi a két bemenetet Csodaországba, majd visszaküldi az egyetlen valós számot (ahogy a kernelek működnek). Feltehető, hogy mindkét világ véges dimenziós, és a kernel lineáris.

Bergengócia királya szeretné megtalálni a $v_1, \ldots, v_n$ pontok közül azt a hármat, amely Csodaországban a legnagyobb területű paralelogrammát adja meg, ezzel erősítvén a kapcsolatot a két birodalom között (feltehető, hogy $n > 3$).

Adj algoritmust, amellyel a király meg tudja találni ezt a három pontot! (Feltehetjük, hogy a három pont az óramutató járásával ellentétes irányban adja meg a paralelogrammát. A negyedik csúcsot a másik három így már meghatározza.) A válaszodat részletesen indokold!

Megoldás: Minden ponthármasra legyen $a = v_1 - v_2$ és $b = v_3 - v_2$ a két oldalvektor. A kernel linearitása miatt ezekre is alkalmazható, és:

1. az oldalhosszak $\|a\| = \sqrt{K(a,a)}$, $\|b\| = \sqrt{K(b,b)}$,

2. a bezárt szög koszinusza $\cos\gamma = \dfrac{K(a,b)}{\|a\|\,\|b\|}$,
3. a szinusza $\sin\gamma = \sqrt{1-\cos^2\gamma}$ (paralelogrammánál nemnegatív),
4. a terület $T = \|a\|\,\|b\|\sin\gamma = \sqrt{K(a,a)\,K(b,b) - K(a,b)^2}$.

Az összes ponthármas közül a legnagyobb területűt választjuk. Ehhez $O(n^3)$ hármast kell kiértékelni. Azért működik, mert a terület csak az oldalhosszaktól és a bezárt szögtől függ, ezeket pedig a kernel által adott skaláris szorzatok meghatározzák.