MAGYAR MI DIÁKOLIMPIA

Elméleti rész

Téli Országos Válogató

2026. október 17.

Név: _____ **Versenyzői Azonosító:** _____

A feladatsor megoldására pontosan **3 óra** áll rendelkezésedre. A feladatsor **22 feladatból áll**, maximálisan **160 pontot ér**.

Ez a feladatsor a **Magyar Mesterséges Intelligencia Diákolimpia** téli válogatójának elméleti része. Papíralapon, segédeszközök használata nélkül kell megoldani.

A feladatok a következő témakörökből származnak: **keresés** (AI Search), **felügyelet nélküli tanulás** (Unsupervised Learning), **felügyelt tanulás** (Supervised Learning), **ajánlórendszerek** (Recommender Systems), **megerősítéses tanulás** (Reinforcement Learning, RL), **modellek kiértékelése** (Model Evaluation), valamint **kernelmódszerek** (Kernel Methods).

A feladatsor két részből áll. A **feleletválasztós kérdéseknél** a választ ezen a feladatlapon jelöld be. A **kifejtős feladatokat** a kiosztott külön lapokon oldd meg, és minden lapra írd fel a nevedet és a feladat sorszámát. A kifejtős feladatoknál a megoldás menetét is írd le, ne csak a végeredményt.

Pontozás a feleletválasztós kérdéseknél. A feleletválasztós kérdéseknek két típusa van.
Egyválaszos kérdések („Válaszd ki az egyetlen helyes választ”): pontosan egy helyes válasz van.

- **3 pont**: pontosan a helyes választ jelölöd be, és csak azt.
- **0 pont**: minden más esetben. Negatív pont nincs.

Több válaszlehetőséges kérdések („Válaszd ki pontosan azokat az állításokat, amelyek igazak”): tetszőleges számú állítás lehet igaz.

- **5 pont**: minden igaz állítást kiválasztasz, és csak azokat (tökéletes válasz).
- **2 pont**: kizárólag igaz állításokat választasz ki, de nem mindegyiket (azaz nem jelölsz be hamis állítást, viszont legalább egy igazat kihagysz).
- **1 pont**: pontosan egy hamis állítást jelölsz be, viszont legalább egy igaz állítást is megjelölsz. A kihagyott igaz állítások száma nem számít.
- **0 pont**: minden más esetben, vagyis ha üresen hagyod a kérdést, ha egyetlen igaz állítást sem jelölsz be, vagy ha két vagy több hamis állítást is bejelölsz. Negatív pont nincs.

Kivétel: ha a helyes válasz az, hogy „A többi állítás közül egyik sem igaz”, akkor csak akkor jár pont (5 pont), ha kizárólag ezt az opciót jelölöd be; minden más esetben 0 pont.

Sok sikert kívánunk!

Feleletválasztós kérdések

Egyválaszos kérdések

Ezeknél a kérdéseknél **pontosan egy** helyes válasz van: 3 pont jár, ha pontosan azt jelölöd be, minden más esetben 0 pont.

1. Van 1000 db 40 dimenziós vektorod, és levetíted őket 2 dimenzióra PCA-val. Hány vektorod marad? Válaszd ki az egyetlen helyes választ:
   - ◯ 2
   - ◯ 20

- ◯ 25
- ◯ 40
- ◯ 80
- ◯ 500
- ◯ 1000
- ◯ 2000
- ◯ A megadott adatokból nem határozható meg.

2. Van 100 dokumentum, minden dokumentum átlagosan 60 tokent tartalmaz, és egy dokumentumban átlagosan 25 féle (egyedi) token található. Hány dimenziósak **pontosan** az ezen az adathalmazon tanított TF-IDF vektorok? Válaszd ki az egyetlen helyes választ:
   - ◯ 25
   - ◯ 60
   - ◯ 100
   - ◯ 2500
   - ◯ 6000
   - ◯ 1560
   - ◯ 156000
   - ◯ A megadott adatokból nem határozható meg.
3. Legyen A egy **szimmetrikus, pozitív definit** mátrix, amelynek ismerjük az SVD-felbontását: $A = U\Sigma V^T$. (Ilyen mátrix esetén a szinguláris felbontás egybeesik a sajátérték-felbontással, azaz $V = U$, és U ortogonális: $U^TU = I$.) Minimum hány **mátrixszorzás** elég ahhoz, hogy kiszámoljuk A^{256}-ot? (Egy diagonális mátrix elemenkénti hatványozása nem számít mátrixszorzásnak.) Válaszd ki az egyetlen helyes választ:
   - ◯ 0
   - ◯ 1
   - ◯ 2
   - ◯ 8
   - ◯ 16
   - ◯ 255
   - ◯ 256
   - ◯ A megadott adatokból nem határozható meg.

Több válaszlehetőséges kérdések

Ezeknél a kérdéseknél tetszőleges számú állítás lehet igaz, a pontozás a fenti, több válaszlehetőséges kérdésekre vonatkozó szabályok szerint történik.

4. A nem informált keresésekkel kapcsolatban válaszd ki pontosan azokat az állításokat, amelyek **igazak**:
   - ◯ Véges állapottérben, az ismétlődő állapotok kiszűrésével a DFS garantáltan talál megoldást, ha létezik megoldás.
   - ◯ A szélességi keresés garantáltan talál megoldást, ha három mélységben van a legközelebbi megoldás.
   - ◯ A szélességi keresést preferáljuk a mélységivel szemben, mivel kevesebb csúcsot néz meg és jobb a memóriaigénye.

- ◯ A szélességi és a mélységi keresés algoritmikailag (tehát az idő és tárhely komplexitást figyelmen kívül hagyva) kizárólag a kiterjesztés sorrendjében tér el.
- ◯ A szélességi és az egységköltségű (Uniform Cost Search) keresés közül csak a szélességi talál garantáltan optimális megoldást különböző élköltség esetén, feltéve, hogy létezik véges távolságra megoldás (véges az elágazási faktor).
- ◯ A szélességi keresés tekinthető az egységköltségű (Uniform Cost Search) keresés speciális változatának.
- ◯ A mélységi keresés tekinthető az egységköltségű (Uniform Cost Search) keresés speciális változatának.
- ◯ A többi állítás közül egyik sem igaz.

5. Egy robot az alábbi 7×7-es rácson mozog (négy irányba léphet, # = fal). S-ből indul, és A* kereséssel megy a G cél felé. Egy cella heurisztikafüggvényének értéke a Manhattan-távolságok összege S-be és G-be, a cél mező esetén a heurisztika 0. Meglátogatott mezőnek azt nevezzük, amelyet kivettünk a nyílt listáról és kiterjesztettünk. A cél mezőt már nem terjesztjük ki, hanem rögtön megállunk, így ezt nem tekintjük meglátogatottnak.

	o0	o1	o2	o3	o4	o5	o6
s0	.	.	.	.	.	.	.
s1	.	S	.	#	.	.	.
s2	.	.	.	#	.	.	.
s3	#	#	#	#	.	.	.
s4	.	.	.	.	.	.	.
s5	.	.	#	#	#	G	.
s6	.	.	.	.	.	.	.

Válaszd ki pontosan azokat az állításokat, amelyek igazak:

- ◯ Minden legkisebb heurisztikaértékű mező az S és G által kifeszített téglalapon belül van (a téglalap oldalait is beleértve).
- ◯ A meglátogatott mezők száma **legalább** 10.
- ◯ A meglátogatott mezők száma **legalább** 11.
- ◯ A meglátogatott mezők száma **legalább** 12.
- ◯ A meglátogatott mezők száma **legfeljebb** 20.
- ◯ A meglátogatott mezők száma **legfeljebb** 22.
- ◯ Van olyan holtverseny-döntés, amelynél az `s4o0` mezőt meglátogatjuk.
- ◯ Van olyan holtverseny-döntés, amelynél az `s5o1` mezőt meglátogatjuk.
- ◯ Ez a keresés tetszőleges rácson garantáltan a legrövidebb utat találja meg ezzel a heurisztikafüggvénnyel.
- ◯ A többi állítás közül egyik sem igaz.

6. Az alábbi kérdésben „K-means" alatt az algoritmus *egyetlen* lefuttatását értjük (nem több véletlen inicializálás közül a legjobb kiválasztását).

   Tegyük fel, hogy az adathalmaz pontjai előre rögzített módon k^* csoportra vannak osztva: ezek a *valódi klaszterek*, k^* pedig a klaszterek *tényleges száma*. Jelölje D a klaszterátmérőt (az azonos valódi klaszterbe tartozó pontok közötti maximális távolság), d_{out} pedig a különböző valódi klaszterekbe tartozó pontok közötti minimális távolságot. Egy klaszterező algoritmus akkor *találja meg a valódi klasztereket*, ha az általa adott felosztás pontosan ez a k^* csoport (a klaszterek sorszámozásától eltekintve).

   Silhouette érték: egy tetszőleges felosztásban az i pontra, amelynek klaszterében rajta kívül legalább még egy pont van, legyen $a(i)$ az i átlagos távolsága a saját klaszterének többi pontjától, $b(i)$ pedig a legkisebb átlagos távolsága egy másik klaszter pontjaitól. Ekkor

$$s(i) = \frac{b(i) - a(i)}{\max\big(a(i), b(i)\big)},$$

egyelemű klaszter pontjára pedig $s(i) = 0$. A felosztás *silhouette score*-ja az $s(i)$ értékek átlaga.

Válaszd ki pontosan azokat az állításokat, amelyek igazak:

- ◯ Ha $d_{out} > D$, akkor meg tudjuk választani a K-means és a hierarchikus klaszterezés paramétereit (a K-means esetén az inicializálási stratégiát, a hierarchikus esetén pedig az összekapcsolási módszert (linkage) is beleértve) úgy, hogy mindkettő biztosan megtalálja a valódi klasztereket.
- ◯ Ha minden távolságot ugyanazzal a $c > 0$ számmal megszorzunk, a silhouette score nem változik.
- ◯ Ha minden (különböző pontok közötti) távolsághoz ugyanazt a $c > 0$ számot hozzáadjuk, a silhouette score nem változik.
- ◯ Két klaszter esetén, ha egy pontot átteszünk a másik klaszterbe (és a régi klaszterében rajta kívül volt még legalább egy pont), akkor ennek a pontnak a silhouette értéke pontosan az ellentettjére változik.
- ◯ Két klaszter esetén, ha egy pontot átteszünk a másik klaszterbe (és a régi klaszterében rajta kívül volt még legalább egy pont), akkor a felosztás teljes silhouette score-ja pontosan az ellentettjére változik.
- ◯ Diszkrét térben elhelyezkedő pontfelhők esetén a hagyományos (folytonos átlagszámítást alkalmazó) K-means és az adatpontokra korlátozott középpontokat használó változat azonos inicializálás esetén garantáltan ugyanahhoz a végső klaszter-kiosztáshoz konvergál.
- ◯ A többi állítás közül egyik sem igaz.

7. Adott a 2D síkon 5 darab, független **csonkított** Gauss-eloszlás, amelyeknek a szórásmátrixa azonos és **izotróp**. A csonkítás azt jelenti, hogy mindegyik eloszlásnál ugyanazon valószínűségisűrűség-küszöbérték alatti pontokat elvetjük.

   Izotróp eloszlás: az eloszlás minden irányban ugyanúgy szóródik. Ez azt jelenti, hogy minden koordináta mentén ugyanakkora a szórás (σ), és a koordináták korrelálatlanok, azaz a szórásmátrix $\Sigma = \sigma^2 I = \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix}$.

   Az eloszlás sugara (R): a legnagyobb távolság, amely a várható érték és egy még **lehetséges** (a csonkítás után is előforduló) pont között felléphet. Nevezzük az **eloszlás területének** azt a síkidomot, ahol előfordulhatnak az adott csonkított eloszlás által generált pontok.

   Mind az 5 eloszlásból **legalább 2-2 pontot** generálunk (a pontok akár egybe is eshetnek), úgy, hogy ezek a csonkítás után is megmaradjanak. Ismert, hogy az 5 eloszlásból 3 az A kategóriához, 2 pedig a B kategóriához tartozik.

   Az adathalmazon agglomeratív hierarchikus klaszterezést futtatunk, a megállási feltétel: pontosan két klaszter marad. Két klaszter (X és Y) távolságát az összekapcsolási módszer (linkage) határozza meg:

   - **Single-linkage:** $D(X, Y) = \min_{x \in X,\, y \in Y} d(x, y)$, a két klaszter legközelebbi pontpárjának távolsága;
   - **Complete-linkage:** $D(X, Y) = \max_{x \in X,\, y \in Y} d(x, y)$, a két klaszter legtávolabbi pontpárjának távolsága.

   A klaszterezéshez a feladatban **Single-linkage**-et használunk, ha mást nem mond az állítás. A szétválasztás *helyes*, ha a kapott 2 klaszter pontosan az A, illetve a B kategóriájú pontokból áll.

   Válaszd ki pontosan azokat az állításokat, amelyek **igazak**:

   - ◯ Mind az 5 eloszlás egyforma sugarú körlapon belül generál pontokat.
   - ◯ Egyetlen eloszlás területén belül két pont távolsága legfeljebb az eloszlás sugarának kétszerese.
   - ◯ Az A kategóriához tartozó 3 területnek feltétlenül metszenie kell egymást ahhoz, hogy a Single-linkage biztosan egy klaszterbe vonja őket.

- ◯ A helyes szétválasztáshoz elengedhetetlen, hogy bármely két A-beli pont közelebb legyen egymáshoz, mint a legközelebbi B-beli ponthoz.
- ◯ Létezik olyan geometriai elrendezés, ahol a Single-linkage garantáltan helyes eredményt ad, míg a Complete-linkage biztosan elrontja azt.
- ◯ Ha eloszlásonként több pontot generálunk (pl. 2 helyett 1000-et), akkor a területek között kisebb távolság is elegendő ahhoz, hogy a szétválasztás a legrosszabb esetben is garantáltan helyes legyen.
- ◯ Ha egy A-hoz és egy B-hez tartozó terület tömegközéppontjának távolsága kisebb, mint $2R$, létezik olyan legrosszabb esetű pontgenerálás, amely garantáltan elrontja a klaszterezést.
- ◯ Ha az azonos kategóriához tartozó területek tömegközéppontjainak maximális távolsága D_{max}, a különböző kategóriákhoz tartozóké minimálisan D_{min}, akkor $D_{max} + 4R < D_{min}$ esetén a szétválasztás garantáltan helyes.
- ◯ Két azonos eloszlásból származó generált pont euklideszi távolsága elérheti a $4R$ értéket is.
- ◯ A többi állítás közül egyik sem igaz.

8. Az alábbi modellekben x_1, x_2, x_3 a bemeneti jellemzők (ismert adatok), y a célváltozó, a $\beta_0, \beta_1, \beta_2$ pedig a tanítás során tanult paraméterek; minden más szám rögzített konstans. Az alábbi modellek közül melyek tekinthetők **lineáris regressziónak**? Válaszd ki pontosan azokat, amelyek azok:
   - ◯ $y = \beta_1 \ln(x_1) + \beta_2 x_2 + \beta_0$
   - ◯ $y = \beta_1 \cos(x_3) + \beta_2 x_1 x_2 + \beta_0$
   - ◯ $y = \ln\left(x_1^{\beta_1} \cdot x_2\right) + \beta_0$
   - ◯ $y = \beta_1 x_1^{\beta_2} + \beta_0$
   - ◯ $y = \beta_1 x_1^2 + \beta_0$
   - ◯ $y = \dfrac{1}{\beta_1 x_1 + \beta_0}$
   - ◯ A többi állítás közül egyik sem igaz.
9. A TF-IDF-ről. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
   - ◯ A TF-IDF egy olyan módszer, amivel tokenekhez készíthetünk beágyazásokat. A hátránya, hogy az ugyanolyan szóalakkal, de különböző jelentéssel rendelkező tokenekhez (többjelentésű szavak, pl. daru, csíp...) ugyanaz a vektor tartozik.
   - ◯ TF-IDF vektorokon is működik a szemantikai algebra, azaz király $-$ férfi $+$ nő $\approx$ királynő típusú összefüggések teljesülnek.
   - ◯ Egy token IDF-súlya annál nagyobb, minél kevesebb dokumentumban fordul elő.
   - ◯ A TF-IDF reprezentáció figyelembe veszi a szavak sorrendjét a dokumentumban.
   - ◯ A TF-IDF mátrix jellemzően ritka (sparse): egy dokumentum vektorában a koordináták túlnyomó része 0.
   - ◯ Ha egy token a korpusz minden dokumentumában előfordul, az IDF-súlya (simítás nélkül) 0 lesz.
   - ◯ A többi állítás közül egyik sem igaz.
10. Az állapotokról, akciókról és jutalmakról. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
    - ◯ A jutalom mindig független az állapottól.
    - ◯ A jutalom értéke nemnegatív.
    - ◯ Egy adott állapotban mindig véges számú akció áll rendelkezésre.
    - ◯ Egy állapot többször is előfordulhat egy trajektória során.
    - ◯ Az állapotátmenetek lehetnek determinisztikusak.

- ◯ Minden trajektória elér egy terminális állapotot.
- ◯ A többi állítás közül egyik sem igaz.

11. A Q-learning algoritmusról. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
    - ◯ On-policy algoritmus.
    - ◯ Off-policy algoritmus.
    - ◯ Célja, hogy megtalálja az optimális $Q^*(s, a)$ függvényt.
    - ◯ Célja, hogy megtalálja az optimális $V^*(s)$ függvényt.
    - ◯ Működési elve, hogy a $V(s)$ értékeket iteratív módon pontosítja, majd ezekből kiszámítja a $Q^*(s, a)$ értékeket.
    - ◯ Működési elve, hogy az összes $Q(s, a)$ értékre felírt Bellman-egyenlet egyenletrendszerét (ez a Q mátrix) analitikus módon megoldja.
    - ◯ A többi állítás közül egyik sem igaz.
12. A Temporal Difference (TD) Learning (időkülönbséges tanulás) algoritmusokról. Válaszd ki pontosan azokat az állításokat, amelyek igazak:
    - ◯ Csak véges számosságú állapottereken működnek.
    - ◯ Mindig on-policy algoritmusok.
    - ◯ Az állapotérték- vagy állapot-akció érték-függvény frissítése mindig egy trajektória végén történik.
    - ◯ A bootstrapping módszerrel becsült értékek alapján frissítenek becsült értékeket.
    - ◯ A többi állítás közül egyik sem igaz.

Kifejtős feladatok

A kifejtős feladatokat a kiosztott külön lapokon oldd meg, a feladat sorszámának feltüntetésével.

13. **(6 pont)** Adott a síkon az alábbi 6 pont:

$$P_1 = (0,0), \quad P_2 = (2,0), \quad P_3 = (0,2), \quad P_4 = (4,4), \quad P_5 = (6,4), \quad P_6 = (4,6).$$

$K = 2$ klasztert keresünk, a kezdeti klaszterközéppontok: $c_1 = (0,0)$ és $c_2 = (2,0)$. A távolság az euklideszi távolság.

   (a) **(2 pont)** Írj pszeudokódot a K-means algoritmushoz!

   (b) **(2 pont)** Végezd el a K-means **egy** iterációját: add meg, melyik pont melyik klaszterbe kerül, és mik lesznek az új klaszterközéppontok!

   (c) **(2 pont)** Változik-e a pontok klaszterbe sorolása a következő iterációban? Ha igen, melyik pont kerül át?

14. **(9 pont)** Írd fel az egyenes illesztésének az egyenletrendszerét a legkisebb négyzetek módszerével a következő pontokra, majd oldd is meg!

$$(1,\,2), \quad (2,\,3), \quad (3,\,5), \quad (4,\,6)$$

15. **(6 pont)** Adott egy adathalmaz, amelyen egy bináris döntési fát (pl. CART algoritmus) tanítunk. A tanítás során a vágások pontosan addig folytatódnak, amíg minden levélcsomópont (leaf) teljesen „tiszta” nem lesz, azaz minden levélben kizárólag egyetlen kategóriába (osztályba) tartozó elemek maradnak. A fa mélységét úgy definiáljuk, mint a gyökércsomóponttól a legmélyebb levélig vezető út éleinek (döntési lépéseinek) a száma (tehát egyetlen vágás után a fa mélysége 1). Mekkora az elméletileg lehetséges legkisebb (minimális) és legnagyobb (maximális) famélység, ha az adathalmaz pontosan 10 különböző osztályba tartozó elemet tartalmaz? Általánosítva, mekkora a minimális és maximális famélység egy N különböző osztályba tartozó elemből álló adathalmaz esetén? (Elég a 10 elemes esetre a végeredményt, az általános esetre pedig a képletet megadni, a helyességüket nem kell bizonyítani.)

16. **(9 pont)** Egy lineáris SVM tartóvektorai a következők:

- a $+1$ osztályban: $\mathbf{x}_1 = (3,\,1)$ és $\mathbf{x}_2 = (1,\,3)$,
- a -1 osztályban: $\mathbf{x}_3 = (0,\,0)$.

Add meg a döntési határ (decision boundary) egyenletét, a $\mathbf{w}$ súlyvektort, a b biast és a margó szélességét!

17. **(7 pont)** Egy Naiv Bayes számítást kell kiértékelned egy orvosi adathalmazon, amely egy betegség meglétét jósolja meg ($Y \in \{\text{Igen}, \text{Nem}\}$), két jellemző alapján:

- X_1: Vérnyomás (folytonos, tegyük fel, hogy osztályonként normális, azaz Gauss-eloszlású),
- X_2: Vércsoport (kategorikus: A, B, AB, O).

Az $Y = \text{Igen}$ osztályhoz $N_{\text{Igen}} = 10$ beteg tartozik, míg az $Y = \text{Nem}$ osztályhoz $N_{\text{Nem}} = 20$ páciens. A tanító adathalmaz statisztikái az Igen osztályhoz:

- X_1 statisztikák: $\mu = 140$, $\sigma^2 = 25$,
- X_2 darabszámok: $A : 6,\ B : 4,\ AB : 0,\ O : 0$.

Egy új beteghez tartozó tesztrekord: $X_1 = 145$, $X_2 = O$.

   (a) **(1 pont)** Számítsd ki a $P(X_1 = 145, X_2 = O \mid Y = \text{Igen})$ likelihood értéket simítás nélkül!

   (b) **(6 pont)** Számítsd ki ugyanezt a likelihood értéket Add-1 (Laplace) simítás használatával a kategorikus jellemzőre!

(A Gauss-sűrűségfüggvény: $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$. A (b) részfeladatnál elég a **képlet behelyettesített alakja**, a szám kiszámolása nem elvárás.)

18. **(5 pont)** Egy adatbázis megsérült, és az alábbi két vektor csak hiányosan olvasható ki belőle (az olvashatatlanná vált értékeket □ jelöli):

$$A = \left(\tfrac{2}{3},\ \square,\ \tfrac{1}{3}\right), \qquad B = \left(\tfrac{1}{3},\ \tfrac{2}{3},\ \square\right)$$

A metaadatokból annyit tudunk, hogy a sérülés előtt mindkét vektor egységvektor volt, és minden koordinátájuk nemnegatív. Mekkora a két vektor koszinusz hasonlósága?

19. **(5 pont)** Van egy jellemződ, X (pl. egy ház mérete) és egy célváltozód, Y (pl. a ház ára). A köztük lévő Pearson-korreláció $r = 0{,}8$. Mekkora lesz az új korrelációs együttható, $r(X', Y')$, ha $X' = -3X + 5$ és $Y' = 2Y - 10$? Indokold a megoldásod!

20. **(6 pont)** Milyen értékek között tud változni a koszinusz hasonlóság értéke neurális háló által előállított szóbeágyazások esetén? Illetve TF-IDF vektorok esetén? A lehető legszűkebb intervallumot add meg! Indokold a megoldásod!

21. **(37 pont) MEeT RICk.** Rick szeret fordítani, csak nem ért hozzá, így kedvenc fordító modelljén dolgozik, melyet szeretne minél jobbra betanítani.

Rick észrevette, hogy a modell nagyon gyakran teljesít egész jól, viszont a hibátlan fordítások aránya csekély. Jobban megvizsgálva, a kimenet jelentős része szinte mindig értelmes és helyes, viszont a modell el-elront egy-egy tokent szinte minden példában.

(a) **(13 pont)** Rick feltevését igazolandó, szeretne egy olyan mérőszámot adni, mely minden egyes kimenethez megadja, hogy mennyire felel meg az elvárt kimenetnek. Ennek a mérőszámnak különösen fontos, hogy jól megkülönböztesse a teljesen hibátlan kimeneteket a hibásaktól. Ugyanakkor, ha már előfordult egy hiba, akkor a további (nem nagyobb) hibákat ne büntesse ugyanolyan mértékben, csupán kisebb súllyal. Emellett Rick azt is szeretné, hogy a módszer folytonos legyen: ha egy kicsit eltérő kimeneti eloszlásokat ad vissza a modell (az egyes pozíciókra), akkor ne változzon sokat a mérőszám értéke (akkor se, ha éppen átbillen a teljesen helyes és a hibás kimenet között ez az érték).

A bemenet egy p sorozat, amelynek minden eleme az adott pozíción lévő tokeneloszlás, amelyet a modell visszaadott. Itt feltehetjük, hogy $p_{k,i} \in [0, 1]$, ahol a k-adik pozíció eloszlása p_k, és $\sum_j p_{k,j} = 1$ (vagyis ténylegesen egy eloszlásról beszélünk). A jelölés kedvéért feltehetjük, hogy a k-adik pozíció elvárt kimenete a $g(k)$-edik elem, vagyis helyes eredmény esetén a $p_{k,g(k)}$ elem értéke a legnagyobb.

Tehát az alábbi pontoknak kell megfelelnie a mérőszámnak:

- Jelentősen visszaesik a teljesítmény az első elrontott token után, viszont a következő elrontott tokent már nem bünteti ugyanilyen mértékben, akár figyelmen kívül is hagyhatja.
- A sikerességnek 0 és 1 közötti értéknek kell lennie (0 a legrosszabb, és 1 a legjobb).
- Kicsi változás a modell kimenetében (p) ne változtasson túl sokat a mérőszámon.

Adj meg egy, a fenti leírásnak megfelelő mérőszámot, és mutasd meg, miért teljesíti a fent megfogalmazott elvárásokat!

(b) **(24 pont)** Rick szeretné úgy kiegészíteni a fenti elvárásait, hogy minden hibás token számítson bele negatívan a kimenetbe, ne csak a legrosszabb, viszont minél kisebb a hiba a legrosszabbhoz képest, annál kevésbé legyen szignifikáns az okozott romlás. Adj meg egy ennek is megfelelő mérőszámot! A válaszodat részletesen indokold!

22. **(16 pont) Kernel magozás.** Hosszú idő után Bergengócia királyának sikerült felvennie a kapcsolatot Csodaország uralkodójával. A művelet nem volt egyszerű, és sajnos a továbbiakban sem lesz az, tekintve, hogy a két ország különböző méretű dimenziókban létezik. A megoldást egy varázskernel (K) biztosítja: a szokásos módon átküldi a két bemenetet Csodaországba, majd visszaküldi az egyetlen valós számot (ahogy a kernelek működnek). Feltehető, hogy mindkét világ véges dimenziós, és a kernel lineáris.

Bergengócia királya szeretné megtalálni a $v_1, \ldots, v_n$ pontok közül azt a hármat, amely Csodaországban a legnagyobb területű paralelogrammát adja meg, ezzel erősítvén a kapcsolatot a két birodalom között (feltehető, hogy $n > 3$).

Adj algoritmust, amellyel a király meg tudja találni ezt a három pontot! (Feltehetjük, hogy a három pont az óramutató járásával ellentétes irányban adja meg a paralelogrammát. A negyedik csúcsot a másik három így már meghatározza.) A válaszodat részletesen indokold!